

基于残差增强运动学模型的无人艇短时轨迹预测方法

赵明艳¹, 吴恭兴*

(上海海事大学海洋科学与工程学院, 上海 201306)

摘要: 针对无人艇短时轨迹预测中记录状态量与位置计算参数不一致导致预测精度下降的问题, 提出一种残差增强运动学轨迹预测方法 (RAP-CT)。基于位置计算运动学参数建立统一运动学参考, 以恒速恒转率模型生成中心预测轨迹, 并利用多层感知机预测航速残差和航向变化率残差, 对运动学递推过程进行修正。基于两类无人艇实测数据开展 2、10 和 20min 预测实验, 并与运动学模型、滤波模型、机器学习模型及深度学习模型进行比较。结果表明, RAP-CT 在各预测时长下均取得最优性能, 20min 预测时终点误差和均方根误差分别为 110.00m 和 84.00m。研究表明, 该方法能够有效抑制误差累积, 提高无人艇短时轨迹预测精度, 并保持运动学可解释性。

关键词: 无人艇; 短时轨迹预测; 恒速恒转率模型; 残差学习

中图分类号: U666.11 **文献标志码:** A

Residual-augmented constant turn-rate model for short-term trajectory prediction of unmanned surface vehicles

Zhao Mingyan¹, Wu Gongxing*

(College of Ocean Science and Engineering, Shanghai Maritime University, Shanghai 201306, China)

Abstract: A residual-augmented constant turn-rate model is proposed for short-term trajectory prediction of unmanned surface vehicles to address the inconsistency between recorded state variables and geometry-based kinematic parameters, which may degrade prediction accuracy. A unified kinematic representation is constructed based on geometry-derived motion parameters. A constant-speed constant-turn-rate model is employed to generate a nominal trajectory. Residuals of surge velocity and heading rate are estimated using a multilayer perceptron and used to correct the kinematic evolution process. Experiments are conducted on two real-world USV datasets under 2, 10 and 20 minute prediction horizons. Comparative evaluations are performed against kinematic models, filtering-based methods, machine learning models, and deep learning approaches. The results show that the proposed method consistently achieves superior performance across all prediction horizons. For the 20-minute prediction task, the endpoint error and root mean square error are 110.00 m and 84.00 m, respectively. It is found that the proposed method effectively suppresses error accumulation, improves short-term trajectory prediction accuracy, and preserves kinematic interpretability.

Key words: unmanned surface vehicle; short-term trajectory prediction; constant turn-rate model; residual learning;

收稿日期: 2026-06-11

修回日期:

基金项目: 国家自然科学基金面上项目 (52271322)

通信作者: 吴恭兴 (1983—), 男, 江西抚州人, 副教授, 博士,。研究方向为船舶操纵与控制。(E-mail)

wugx@shmtu.edu.cn

0 引言

无人艇在海洋环境监测、目标搜救与自主航行等任务中的广泛应用，对短时轨迹预测提出了迫切需求^[1]。准确的短时轨迹预测是无人艇感知、决策与路径规划模块协同运行的基础，直接关系到航行安全与任务效能^[2]。随着船载导航与定位技术的普及，大量实测航行数据为数据驱动的轨迹预测提供了支撑，但如何有效利用这些数据进行运动学一致且可解释的短时预测，仍是亟待解决的问题^[3]。

传统方法主要基于运动学模型开展轨迹外推。恒速与恒速恒转率等模型结构简洁、具有明确的运动学可解释性，在船舶状态估计与目标跟踪中得到了广泛应用。BAR-SHALOM 等^[4]系统建立了恒速与协调转弯模型的状态转移方程，为后续滤波与预测算法奠定了理论基础；ZHAI 等^[5]进一步提出恒速变化率与恒转率统一模型，通过粒子滤波验证了运动学模型在机动目标跟踪中的有效性。然而，这类模型假设预测时域内运动参数恒定，难以适应实测数据中的局部加减速、持续转向及环境扰动，导致预测误差随时间快速累积。此外，在无人艇实测航行数据中，记录状态量（如对地航速、对地航向）与由相邻位置点计算得到的几何运动学参数之间存在不一致；若直接采用记录状态量进行运动学递推，将引入输入基准偏差，进一步放大预测误差^[6]。现有研究通常默认记录状态量可直接作为运动学递推输入，对上述系统性差异缺乏显式分析与处理机制。

近年来，深度学习模型被引入船舶轨迹预测领域。长短期记忆网络、门控循环单元及 Transformer 等架构能够捕捉航行数据中的非线性时序依赖，在拟合复杂轨迹模式方面表现出优势。LIN^[7]等提出基于 Transformer 的 HDFormer 模型，通过多源数据融合实现渔船轨迹预测；JIANG 等^[8]构建时空多图融合网络，在智能航行场景下取得了较好的预测精度；GUO 等^[9]引入船舶影响 LSTM 模型，结合不确定性量化以应对复杂水域交互。然而，现有深度学习方法多直接回归未来坐标或运动状态，属于“黑箱”预测模式，缺乏显式运动学约束，导致轨迹生成过程运动学可解释性不足，长时域外推时易出现非运动学偏移。此外，这类模型通常假设输入数据质量良好，较少关注实测数据中记录状态量与位置计算参数之间的系统性差异。

为兼顾运动学可解释性与数据驱动精度，部分研究尝试将运动学知识嵌入数据驱动框架。LANG 等^[10]面向船舶航速预测，构建了灰箱模型，将运动学约束与数据驱动方法结合，取得了优于纯黑箱模型的精度；ZHAO 等^[11]将运动学方程嵌入神经网络，通过有限差分损失函数提升船舶轨迹预测的运动学一致性；NIELSEN 等^[12]以机器学习增强船舶数字孪生操纵预测，利用全尺度实测记录修正运动学模型残差。然而，上述研究多面向理想仿真条件或特定操纵场景，面向无人艇实测数据的运动学与数据融合短时预测方法仍较为匮乏，尤其缺乏对实测数据中运动学基准不一致问题的显式处理机制，且较少在预测输出中构建经验误差范围以支撑工程决策。

针对上述问题，本文提出一种残差增强运动学轨迹预测方法（RAP-CT）。主要贡献包括：（1）通过分析记录状态量与位置计算运动学参数的一致性，明确采用位置计算运动学参数作为统一运动学参考，避免递推基准偏差；（2）以 CV-CT 模型生成中心预测轨迹，利用多层感知机（MLP）估计航速残差与航向变化率残差，并按归一化时间比例平滑注入运动学递推过程，既保留轨迹生成的运动学可解释性，又通过数据驱动修正缓解误差累积；（3）基于历史回测构建经验误差范围，直观表达预测误差随时域扩展的趋势，并在转向机动场景下补充验证模型的适用边界。

1 实测航行数据来源与特征分析

为建立适用于无人艇实测航行数据的短时轨迹预测方法，本文首先说明实验数据来源、数据预处理

理方法和运动学参数计算方式。本文将数据记录字段中直接给出的对地航速、对地航向和艏向等称为记录状态量；将由相邻位置点计算得到的航速、航向和航向变化率等称为位置计算运动学参数。由于二者来源不同，本文进一步分析记录状态量与位置计算运动学参数之间的一致性，并据此确定后续模型采用的统一运动学参考，为残差增强运动学预测模型提供建模依据。

1.1 数据来源

本文采用两类无人艇实测航行数据开展实验分析。数据集 A 为无人艇历史航行轨迹记录数据，包含时间、经纬度、对地航速、对地航向和艏向等字段，主要用于短时轨迹预测主实验、状态一致性分析和模型性能对比。数据集 B 为转向实验状态数据，包含转向实验过程中的位置、航速、航向及相关控制状态信息，主要用于后续转向机动场景下的补充验证。

两类数据的采集场景、记录字段和用途不同，因此不直接混合作为统一训练集。本文重点关注实测航行记录中状态字段与位置序列之间的一致性。

为直观说明两类数据的轨迹形态，图 1 给出了数据集 A 和数据集 B 在局部东-北-天坐标系（east-north-up, ENU）下的轨迹概览。




图 1 数据集 A 与数据集 B 的 ENU 轨迹

由图 1 可见，数据集 A 反映无人艇历史航行过程中的轨迹变化，数据集 B 反映转向实验过程中的局部机动轨迹。两类数据的轨迹尺度和应用场景不同，因此本文将数据集 A 用于主预测实验，将数据集 B 用于转向机动场景补充验证。后续运动学参数计算和预测误差统计均在统一坐标系下进行。

1.2 数据预处理

为保证轨迹几何分析和预测实验的可靠性，本文首先对原始数据进行预处理。预处理包括按时间戳排序、删除重复时间记录、检查关键字段缺失情况，并将经纬度坐标转换至局部东-北-天平面坐标系^[13]。转换后目标位置以米为单位表示，用于后续轨迹几何计算、运动学参数构造和预测误差统计。

数据集 A 中对地航速原始单位为 kn。本文在数据字段说明中保留原始单位含义，在后续运动学参数计算、轨迹递推和误差统计中统一换算为 m/s。对于航向角参数，为避免角度在 0° 和 360° 附近跳变影响差分计算，本文在计算航向变化率前进行角度连续化处理^[14]。

完成上述处理后，本文基于相邻位置点计算几何航速、几何航向和几何航向变化率等运动学参数，并进一步比较记录状态量与位置计算运动学参数之间的一致性。

1.3 运动学参数计算

无人艇轨迹预测需要首先明确运动学参数的计算来源。记录状态量来自数据记录字段，位置计算

运动学参数来自相邻位置点之间的空间变化。二者具有不同来源，因此并不必然完全一致。为构建统一的运动学参考，需基于相邻位置点计算局部平面位移、几何航速及几何航向等参数，计算方式如下：

$$\begin{cases} \Delta x_k = R_e(\lambda_k - \lambda_{k-1})\cos\left(\frac{\phi_k + \phi_{k-1}}{2}\right) \\ \Delta y_k = R_e(\phi_k - \phi_{k-1}) \end{cases} \quad (1)$$

式（1）中： k 为采样时刻索引，由相邻位置点 t_{k-1} 与 t_k 计算得到的位移、时间差及几何运动学参数均以以下标 k 表示，并作为时刻 t_k 处可获得的几何运动状态估计； ϕ_k 和 λ_k 分别为第 k 个采样时刻的纬度和经度，以弧度制表示； R_e 为地球半径； Δx_k 和 Δy_k 分别为局部东向位移和北向位移。

基于上述位移，可进一步求解几何航速与几何航向：

$$\begin{cases} v_{g,k} = \frac{\sqrt{\Delta x_k^2 + \Delta y_k^2}}{\Delta t_k} \\ \psi_{g,k} = \text{atan2}(\Delta x_k, \Delta y_k) \end{cases} \quad (2)$$

式（2）中： Δt_k 为时间差； $v_{g,k}$ 和 $\psi_{g,k}$ 分别为由相邻位置点计算得到的几何航速和几何航向； atan2 为四象限反正切函数，采用以北向为0、顺时针为正的航向角定义，故输入顺序取为东向位移和北向位移。

为避免航向角在 0° 和 360° 附近跳变影响差分计算，需对 $\psi_{g,k}$ 进行角度展开，记展开后的连续几何航向为 $\tilde{\psi}_{g,k}$ 。由此可得几何航向变化率和几何航速变化率：

$$\begin{cases} \omega_{g,k} = \frac{\tilde{\psi}_{g,k} - \tilde{\psi}_{g,k-1}}{\Delta t_k} \\ a_{g,k} = \frac{v_{g,k} - v_{g,k-1}}{\Delta t_k} \end{cases} \quad (3)$$

式（3）中： $\omega_{g,k}$ 为几何航向变化率； $a_{g,k}$ 为几何航速变化率。

上述位置计算运动学参数与轨迹位置变化直接对应，后续将其作为模型初始化、残差学习和预测误差评估的共同参考。

1.4 记录状态量与位置计算参数一致性分析

实测航行数据中的记录状态量与位置计算运动学参数并不总是严格一致。若直接使用记录字段中的对地航速和对地航向进行运动学递推，可能造成输入基准偏差，并影响后续轨迹预测结果。因此，需对二者进行一致性分析。记录对地航速换算与速度误差计算方式如下：

$$\begin{cases} v_{r,k} = 0.5144\text{SOG}_k \\ e_{v,k} = |v_{r,k} - v_{g,k}| \end{cases} \quad (4)$$

式（4）中： $v_{r,k}$ 为记录字段中的对地航速换算值； SOG_k 为记录字段中的原始对地航速； $e_{v,k}$ 为速度误差。

差。

为分析记录航速与位置计算航速之间的一致性，本文比较 $v_{g,k}$ 和 $v_{r,k}$ 的关系，结果如图 2 所示。图中横坐标为记录对地航速，纵坐标为几何航速。若二者完全一致，散点应主要分布在对角线附近。




图 2 数据集 A 记录对地航速与几何航速一致性分析散点图

由图 2 可见，在几何航速接近 0 的样本区域，记录对地航速仍存在明显非零分布，说明记录航速与位置计算航速之间存在不一致。

为排除位置计算过程导致的大范围异常，本文对相邻样本时间间隔和相邻位移进行检查。结果显示，相邻样本时间间隔和位移统计未显示由坐标转换或位置计算错误引起的大范围异常。因此，图 2 中观测到的差异主要反映记录状态量与位置计算运动学参数之间的不一致，而非位置计算错误所致。

为进一步量化记录航速与几何航速之间的差异，本文从速度误差和滞后检验两方面进行统计。速度误差在 $v_{r,k} \leq 1.5$ 的限幅区间内统计；滞后检验的搜索范围为 $\pm 600s$ ，互相关计算前采用差分去趋势处理。统计结果见表 1。

表 1 数据集 A 记录对地航速与几何航速一致性统计

类别	指标	数值
速度误差	MAE/ $m \cdot s^{-1}$	0.903
速度误差	RMSE/ $m \cdot s^{-1}$	0.907
滞后检验	峰值时滞/s	-330
滞后检验	峰值相关系数	0.026
滞后检验	零时滞相关系数	0.015
注：MAE 为平均绝对误差（mean absolute error）；RMSE 为均方根误差（root mean square error）。		

由表 1 可知，记录对地航速与几何航速之间存在明显数值偏差。滞后检验中，峰值相关系数和零时滞相关系数均较低，说明该差异不能简单归因于固定时间延迟。

除航速外，后续预测模型还需要使用航向变化率进行轨迹递推。为说明航向变化率变量的参考来源，本文进一步比较由记录对地航向差分得到的航向变化率与由几何航向差分得到的航向变化率，结果如图 3 所示。




图 3 数据集 A 记录航向变化率与几何航向变化率对比

由图 3 可见，两类航向变化率在局部变化幅度上存在差异。记录航向变化率整体变化幅度较小，而位置计算运动学参数能够反映更明显的局部航向变化。该结果说明，仅依赖记录状态量构造航向变化率可能低估局部转向特征。因此，后续模型采用位置计算运动学参数作为统一运动学参考，并对航速残差和航向变化率残差进行建模。航速和航向变化率差异为后续残差修正变量选择提供了依据，其独立贡献将在实验部分通过消融分析进一步验证。

需要说明的是，本文所称“统一运动学参考”是指在当前数据条件下，由相邻位置点计算得到的运动学参数与轨迹位置变化具有直接对应关系，因此被选定为模型初始化、残差学习和预测误差评估的共同基准。该参考仍可能受定位误差、采样间隔和局部轨迹波动影响。

综合上述分析，数据集 A 中记录状态量与位置计算运动学参数之间存在较明显差异。若直接采用记录状态量进行运动学递推，可能造成预测模型输入基准不一致。为降低该问题对短时轨迹预测的影响，后续章节将以位置计算运动学参数作为统一运动学参考，并在基础运动学递推框架下引入残差修正机制。

2 残差增强运动学轨迹预测模型

基于第一章建立的统一运动学参考，本文构建残差增强运动学轨迹预测模型（residual-augmented prediction with constant turn rate, RAP-CT）。该方法以恒速恒转率模型（constant velocity and constant turn rate, CV-CT）生成中心预测轨迹，并利用多层感知机（multilayer perceptron, MLP）对预测航速残差和航向变化率残差进行建模，再将残差按归一化时间比例平滑注入运动学递推过程。RAP-CT 仅在显式运动学模型中修正关键运动学变量，轨迹位置仍由递推方程生成。该模型既避免了直接采用记录状态量导致的递推基准不一致问题，同时避免了黑箱模型直接回归未来坐标造成的运动学解释不足问题。

2.1 基于 CV-CT 的中心轨迹预测模型

短时轨迹预测需要在预测起点处给定初始位置和运动状态。设原始轨序列中第 k 个采样时刻为预测起点，其局部平面位置为 (x_k, y_k) 。预测时长为 T ，本文取 $T=2$ 、 10 和 20min 。预测过程共包含 N 个递推步，第 n 个预测步的时间间隔为 Δt_n 。CV-CT 假设预测时域内航速和航向变化率保持不变，其递推形式为

$$\begin{cases} \psi_{k,n+1} = \psi_{k,n} + \omega_{g,k} \Delta t_n \\ x_{k,n+1} = x_{k,n} + v_{g,k} \sin \psi_{k,n} \Delta t_n \\ y_{k,n+1} = y_{k,n} + v_{g,k} \cos \psi_{k,n} \Delta t_n \end{cases} \quad (5)$$

式（5）中： $(x_{k,n}, y_{k,n})$ 为预测起点递推到第 n 个预测步的位置坐标； $\psi_{k,n}$ 为第 n 预测步的航向角。初始条件为 $x_{k,0} = x_k$ 、 $y_{k,0} = y_k$ 、 $\psi_{k,0} = \psi_{g,k}$ 。

但在实测数据中，无人艇存在加减速与转向变化，仅依赖预测起点处的 $v_{g,k}$ 和 $\omega_{g,k}$ 外推，容易造成预测误差随时长累积因此需引入残差修正机制。

2.2 MLP 残差修正模型

在 CV-CT 中心轨迹预测基础上，本文利用 MLP 估计航速残差和航向变化率残差^[15]。残差修正是作用于 CV-CT 递推中的航速和航向变化率，以保持轨迹生成过程的运动学解释。

1) 残差标签构造

训练时，在预测终点附近取一段短窗口，并计算该窗口内几何航速和几何航向变化率的中位数，分别记为 $\bar{v}_{g,k,T}$ 和 $\bar{\omega}_{g,k,T}$ 。

航速残差和航向变化率残差定义为

$$\begin{cases} \Delta v_{k,T} = \bar{v}_{g,k,T} - v_{g,k} \\ \Delta \omega_{k,T} = \bar{\omega}_{g,k,T} - \omega_{g,k} \end{cases} \quad (6)$$

式（6）中： $\Delta v_{k,T}$ 和 $\Delta \omega_{k,T}$ 分别为预测时长 T 下的航速残差和航向变化率残差。该残差表征了预测起点状态相对于未来短时运动趋势的系统性偏差。

2) 输入特征与网络结构

设 $\mathbf{z}_k(T)$ 为预测起点 k 前历史窗口内构建的运动学统计特征向量。为保证输入信息与统一运动学参考一致，本文使用由相邻位置点计算得到的运动学参数构造输入特征。具体而言， $\mathbf{z}_k(T)$ 包含预测起点几何航速、预测起点几何航向变化率、历史窗口内几何航速中位数、历史窗口内几何航向变化率中位数、历史窗口内几何航速变化率绝对值中位数、历史窗口内几何航速标准差、历史窗口内几何航向变化率标准差、预测时长归一化量、初始几何航向正弦值和初始几何航向余弦值，共 10 维特征。

其中，中位数和标准差均在预测起点前的历史窗口内计算；几何航速变化率由相邻位置点计算得到。 $T/T_{\max}$ 表示预测时长归一化量。初始几何航向采用正弦值和余弦值共同表示，以避免航向角在 0° 和 360° 附近产生环绕不连续问题。

MLP 残差预测模型表示为

$$\begin{bmatrix} \Delta v_{k,T} \\ \Delta \omega_{k,T} \end{bmatrix}^T = f_\theta(\mathbf{z}_k(T)) \quad (7)$$

式（7）中： $f_\theta(\cdot)$ 为 MLP 映射函数， θ 为网络参数； $\Delta v_{k,T}$ 和 $\Delta \omega_{k,T}$ 分别为模型预测得到的航速残差和航向变化率残差。

本文 MLP 采用 3 层全连接网络，输入层维度为 10，隐藏层包含 64 个神经元并采用 ReLU 激活函数，输出层维度为 2。

3) 损失函数

为保持模型训练的稳定性，本文采用平均绝对误差（mean absolute error, MAE）作为残差预测损失函数：

$$\mathcal{L} = \frac{1}{B} \sum_{k=1}^B \left(\left| \Delta v_{k,T} - \Delta v_{k,T} \right| + \left| \Delta \omega_{k,T} - \Delta \omega_{k,T} \right| \right) \quad (8)$$

式（8）中：\$B\$ 为训练批次样本数；\$\Delta v_{k,T}\$ 和 \$\Delta \omega_{k,T}\$ 分别为第 \$k\$ 个样本的预测航速残差和预测航向变化率残差；\$\Delta v_{k,T}\$ 和 \$\Delta \omega_{k,T}\$ 别为对应的真实残差标签。

由此，MLP 残差修正模型的作用可概括为：根据预测起点前历史窗口内的位置计算运动学参数，估计预测起点状态相对于未来短时运动趋势的偏差。该残差是在后续 RAP-CT 模型中修正 CV-CT 的有效航速和有效航向变化率。

2.3 RAP-CT 模型与误差控制

本文将 CV-CT 中心轨迹预测与 MLP 残差修正结合构建 RAP-CT 模型。模型首先基于历史窗口构造特征，由 MLP 预测航速与航向变化率残差，再按归一化时间比例逐步注入 CV-CT 递推过程，得到修正后的轨迹。

由于残差标签由预测起点状态与预测终点附近统计状态之间的差异构造，不能直接视为各预测步的真实瞬时残差。若将残差一次性加入预测起点状态，容易造成递推初始状态突变。为使残差修正随预测过程逐步发挥作用，本文采用离散归一化比例进行平滑注入：

$$\alpha_n = \frac{n}{N}, \quad n=1,2,\dots,N \quad (9)$$

式（9）中：\$\alpha_n \in \{0,1\}\$ 为第 \$n\$ 个预测步的归一化时间比例。

第 \$n\$ 个预测步的有效航速和有效航向变化率分别定义为

$$\begin{cases} v_{k,n}^* = \text{clip}(v_{g,k} + \alpha_n \Delta v_{k,T}, 0, v_{\max}) \\ \omega_{k,n}^* = \text{clip}(\omega_{g,k} + \alpha_n \Delta \omega_{k,T}, -\omega_{\max}, \omega_{\max}) \end{cases} \quad (10)$$

式（10）中：\$\text{clip}(\cdot)\$ 为边界截断函数；\$v_{\max}\$ 和 \$\omega_{\max}\$ 分别为由历史数据统计得到的航速和航向变化率的 99% 分位数上限。该约束可有效避免负航速或异常高转向率等非物理状态。

将式(10)代入 CV-CT 递推过程，得到 RAP-CT 的轨迹更新公式：

$$\begin{cases} \psi_{k,n+1} = \psi_{k,n} + \omega_{k,n}^* \Delta t_n \\ x_{k,n+1} = x_{k,n} + v_{k,n}^* \sin(\psi_{k,n}) \Delta t_n \\ y_{k,n+1} = y_{k,n} + v_{k,n}^* \cos(\psi_{k,n}) \Delta t_n \end{cases} \quad (11)$$

为说明 RAP-CT 的整体流程，图 4 给出了模型结构示意图。模型首先基于位置计算运动学参数构建历史窗口特征；然后由 MLP 预测航速残差和航向变化率残差；最后将残差按归一化时间比例注入 CV-CT 递推，得到中心预测轨迹。




图4 RAP-CT 模型结构示意图

RAP-CT 的误差控制主要体现在两个方面。第一，残差修正变量限定为航速和航向变化率，避免直接回归未来坐标导致轨迹生成过程缺乏运动学解释。第二，残差注入过程采用归一化比例平滑展开，并通过历史统计边界进行截断，从而降低残差预测异常值对轨迹递推的影响。

从误差传播角度看，航速误差直接影响沿航向方向的位置累积，而航向变化率误差通过航向积分进一步影响轨迹方向，导致误差逐步放大。因此同时修正航速残差和航向变化率残差有助于抑制递推误差扩展。

2.4 经验误差范围表达

RAP-CT 输出中心预测轨迹。为表征预测误差随时间扩展趋势，本文基于历史回测样本终点误差构建经验误差范围表达。

预测时长 T 下预测误差 $e_{k,T}$ 、经验误差半径 $r_p(T)$ ，以及按预测步展开的经验范围宽度 $d_{p,n,T}$ 可统一表示为：

$$\begin{cases} e_{k,T} = \sqrt{(\hat{x}_{k,T} - x_{k,T})^2 + (\hat{y}_{k,T} - y_{k,T})^2} \\ r_p(T) = Q_p(e_{k,T}) \\ d_{p,n,T} = \rho_n \cdot r_p(T) \end{cases} \quad (12)$$

式(12)中： $(\hat{x}_{k,T}, \hat{y}_{k,T})$ 和 $(x_{k,T}, y_{k,T})$ 分别为预测时长 T 下的预测终点与真实终点坐标； $Q_p(\cdot)$ 表示第 p 分位数，本文取 $p=0.50$ 和 $p=0.90$ ，分别对应典型误差范围和较大误差范围。




图 5 2、10 和 20 min 预测轨迹及经验误差范围示意

由图 5 可见，经验误差范围能够直观反映预测误差随预测时长增加而扩展的趋势。短时预测下，经验误差范围较小；随着预测时长增加，误差范围逐渐扩大。该结果说明，中心预测轨迹可以表达未来运动趋势，而经验误差范围可以补充说明不同预测时长下的误差尺度。

该误差范围反映预测误差随时间增长的扩展趋势，但不对应严格概率意义上的置信区间，若需概率保证需进一步引入分位数回归或共形预测方法。

3 实验结果与分析

3.1 实验设置与评价指标

数据集 A 按预测起点索引的时间顺序划分为训练集、验证集和测试集，比例为 0.65: 0.15: 0.20，以避免相邻滑动窗口随机划分造成信息泄漏。预测时长设置为 2、10 和 20min。RAP-CT 中残差网络采用 Adam 优化器训练，学习率为 2×10^{-3} ，权重衰减系数为 1×10^{-4} ，最大训练轮次为 80；每轮训练后在验证集上评估，并保留验证损失最优的模型参数。全部模型随机种子固定为 42。

为增强对比实验的充分性，本文设置 5 类对比方法。它们包括基础运动学模型、滤波模型、传统机器学习模型、深度时序模型和消融模型。基础运动学模型包括 CV-Heading 和 CV-CT；滤波模型包括 KF-CV 和 IMM-CVCA^[16]；传统机器学习模型包括随机森林(random forest, RF)和梯度提升决策树(gradient boosting decision tree, GBDT)^[17]；深度时序模型包括长短期记忆网络(long short-term memory, LSTM)、门控循环单元(gated recurrent unit, GRU)、序列到序列(sequence to sequence, Seq2Seq)模型^[18]和 Transformer；消融模型包括 RAP-CT-dv-only 和 RAP-CT-dw-only。

除基础运动学模型和滤波模型外，其余残差类方法均预测对地航速残差和对地航向变化率残差，再经 CT 递推生成未来轨迹。该设置使不同残差模型具有一致的轨迹生成方式，便于比较残差估计能力及其对轨迹递推误差的影响。

实验采用终点误差(endpoint error, EPE)、均方根误差(root mean square error, RMSE)、相对改善率和胜率评价预测性能。EPE 用于衡量预测终点偏差，RMSE 用于衡量整个预测时域内的轨迹误差。第 m 个测试窗口的 EPE 和 RMSE 分别为：

$$\begin{cases} e_{\text{EPE},m}(T) = \sqrt{(\hat{x}_{m,N_T} - x_{m,N_T})^2 + (\hat{y}_{m,N_T} - y_{m,N_T})^2} \\ e_{\text{RMSE},m}(T) = \sqrt{\frac{1}{N_T} \sum_{n=1}^{N_T} [(\hat{x}_{m,n} - x_{m,n})^2 + (\hat{y}_{m,n} - y_{m,n})^2]} \end{cases} \quad (13)$$

式 (13) 中： $e_{\text{EPE},m}(T)$ 和 $e_{\text{RMSE},m}(T)$ 为第 m 个测试窗口的终点误差和均方根误差； T 为预测时长； N_T 为第 m 个测试窗口包含的预测步数； $(\hat{x}_{m,n}, \hat{y}_{m,n})$ 为第 m 个测试窗口第 n 个预测步的预测位置； $(x_{m,n}, y_{m,n})$ 为对应的真实位置。

由于每个预测时长下包含多个测试窗口，后续表中的 EPE 和 RMSE 均取全部测试窗口上的均值，用于表征模型在测试集上的总体预测性能：

$$\begin{cases} E_{\text{EPE}}(T) = \frac{1}{M} \sum_{m=1}^M e_{\text{EPE},m}(T) \\ E_{\text{RMSE}}(T) = \frac{1}{M} \sum_{m=1}^M e_{\text{RMSE},m}(T) \end{cases} \quad (14)$$

式（14）中： $E_{\text{EPE}}(T)$ 和 $E_{\text{RMSE}}(T)$ 为测试集上全部测试窗口的平均终点误差和平均均方根误差； M 为测试窗口总数。

相对改善率用于表征 RAP-CT 相对于对比模型的误差降低幅度，定义为

$$\eta = \frac{E_{\text{base}} - E_{\text{RAP}}}{E_{\text{base}}} \times 100\% \quad (15)$$

式（15）中： η 为相对改善率； E_{base} 为对比模型误差； E_{RAP} 为 RAP-CT 误差。

为避免单一相对改善率受个别窗口影响，本文同时统计绝对下降量均值、中位改善率和胜率。其中，胜率表示 RAP-CT 误差小于对比模型误差的测试窗口比例。

3.2 多模型预测性能对比

为比较不同方法在无人艇短时轨迹预测任务中的性能，表 2 和表 3 分别给出了各模型在 2、10 和 20min 预测时长下的平均 EPE 和 RMSE，图 6 和图 7 给出了对应的柱状对比结果。

表 2 不同模型在不同预测时长下的终点误差统计

方法	2min	10min	20min
CV-Heading	23.72	123.98	241.36
CV-CT	23.72	123.98	241.47
KF-CV	74.86	380.53	763.89
IMM-CVCA	74.86	380.53	763.89
RF	17.88	72.25	127.81
GBDT	17.15	73.28	127.64
LSTM	20.68	97.43	179.91
GRU	19.11	86.89	153.23
Seq2Seq	20.24	95.24	172.74
Transformer	17.90	78.36	132.38
RAP-CT	13.14	61.18	110.00
注：单位均为 m。			

由表 2 可知，RAP-CT 在 3 个预测时长下均取得最低 EPE，说明其对预测终点偏差具有较好的抑制作用。表中的单残差模型用于与后续消融实验衔接，其具体作用在 3.3 节分析。

表 3 不同模型在不同预测时长下的均方根误差统计

方法	2min	10min	20min
CV-Heading	13.68	71.42	143.73
CV-CT	13.67	71.42	143.74
KF-CV	43.28	219.26	439.16
IMM-CVCA	43.28	219.26	439.16
RF	11.93	53.32	97.21
GBDT	11.63	53.84	97.15
LSTM	13.08	62.96	119.98
GRU	12.41	58.92	110.35

Seq2Seq	12.91	62.20	117.82
Transformer	11.94	56.00	100.99
RAP-CT	9.19	44.55	84.00
注：单位均为 m。			

由表 3 可知，RAP-CT 在整体轨迹误差上同样保持最优，说明残差修正不仅降低终点偏差，也改善了预测时域内的轨迹整体偏移。




图 6 不同模型终点误差柱状图对比




图 7 不同模型均方根误差柱状图对比

由图 6 和图 7 可见，基础运动学模型（CV-Heading、CV-CT）假设预测时域内运动参数恒定，无法反映实测数据中的局部加减速与转向机动，且航向误差通过三角函数项积分后放大为横向位移误差，导致误差随预测时长迅速累积。滤波模型（KF-CV、IMM-CVCA）依赖高斯噪声假设与状态更新机制，对非高斯、强机动的实测航行数据适应性不足，状态更新滞后进一步放大了预测偏差。传统机器学习模型（RF、GBDT）与深度时序模型（LSTM、GRU、Transformer）虽具备非线性拟合能力，但直接回归未来坐标或残差，缺乏显式运动学递推约束，长时域外推时易出现局部过度偏转或跟踪不足。相比之下，RAP-CT 在保持 CV-CT 运动学骨架的前提下，对航速和航向变化率进行数据驱动的残差修正，在各预测时长下均表现出更稳定的误差抑制能力。

为进一步分析 RAP-CT 相对于中心运动学骨干 CV-CT 的稳定性，表 4 给出了逐窗口改善统计。

表 4 RAP-CT 相对 CV-CT 的逐窗口改善统计

预测时长/min	指标	绝对下降量均值/m	中位改善率/%	胜率/%
2	EPE	10.58	47.11	84.38

2	RMSE	4.48	35.01	84.38
10	EPE	62.80	51.45	90.62
10	RMSE	26.86	37.81	87.50
20	EPE	131.47	53.70	78.12
20	RMSE	59.74	41.83	87.50

由表 4 可知，RAP-CT 相对于 CV-CT 的优势是在多数测试窗口中均能取得误差下降。随着预测时长增加，绝对下降量整体增大，说明残差修正主要作用于中长短时域下的误差累积过程。20min 任务中 EPE 胜率相对降低，表明在较长预测时域内，突发机动、持续转向或局部状态变化仍可能削弱残差修正效果，这也构成后续转向机动场景补充验证的分析依据。

3.3 残差消融与机制分析

为分析 RAP-CT 中航速残差和航向变化率残差的作用，实验首先比较 MLP 预测残差与参考残差之间的关系，结果见图 8。




图 8 残差预测值与参考值散点图

由图 8 可见，MLP 对逐窗口残差的点对点拟合能力有限。因此，RAP-CT 为在受约束运动学递推中提供方向性修正。该结果与本文残差标签的构造方式一致，即残差主要用于补偿预测起点状态与未来短时运动趋势之间的偏差。

为进一步验证不同残差项的独立贡献，本文设置仅修正航速残差的 RAP-CT-dv-only 和仅修正航向变化率残差的 RAP-CT-dw-only，并与 CV-CT 和完整 RAP-CT 进行比较，结果见表 5。

表 5 残差修正消融实验结果

方法	2 min EPE	10 min EPE	20 min EPE	2 min RMSE	10 min RMSE	20 min RMSE
CV-CT	23.72	123.98	241.47	13.67	71.42	143.74
RAP-CT-dv-only	13.21	66.56	133.66	9.22	46.41	93.76
RAP-CT-dw-only	23.62	105.43	155.01	13.67	66.35	117.59
RAP-CT	13.14	61.18	110.00	9.19	44.55	84.00

注：单位均为 m。

结果表明，航速残差主要影响轨迹尺度误差，航向变化率残差主要影响轨迹形状误差。两者在不同预测时域下表现出互补性，联合使用可获得最优性能。

3.4 代表性起点结果分析

为进一步说明不同模型预测误差的轨迹形态差异，本文选取测试集中代表性高误差起点进行可视化分析，结果见图 9。




图 9 代表性起点下不同模型的轨迹对比

由图 9 可见，基础运动学模型和滤波模型主要沿预测起点处的运动趋势外推，难以及时反映后续轨迹弯曲，因此在转向区域容易产生明显偏移。传统机器学习模型和深度时序模型能够一定程度上修正外推轨迹，但在局部弯曲段仍存在过度偏转或跟踪不足的问题。

相比之下，RAP-CT 的预测轨迹更接近真实轨迹。其原因在于，模型是在 CV-CT 递推框架中联合修正航速残差和航向变化率残差，从而同时调节位移尺度和轨迹弯曲趋势。与单残差消融模型相比，完整 RAP-CT 在该代表性起点下表现出更稳定的轨迹跟踪效果，进一步说明两类残差项具有互补作用。

3.5 转向机动场景补充验证

为进一步考察 RAP-CT 在转向机动条件下的适用性，本文基于数据集 B 开展补充验证。根据预测起点处航向变化率筛选转向窗口，并根据预测时域内航向变化率持续超过阈值的比例 $\omega = 0.003\text{rad/s}$ 筛选持续机动窗口^[19]，比较 RAP-CT 与 CV-CT 的预测误差，结果见表 6。

表 6 转向与持续机动场景下的误差统计

场景	预测时长/min	方法	EPE 均值/m	RMSE 均值/m
转向窗口	2	CV-CT	23.11	13.44
转向窗口	2	RAP-CT	17.77	11.12
转向窗口	10	CV-CT	98.36	59.31

转向窗口	10	RAP-CT	70.31	47.18
转向窗口	20	CV-CT	186.28	109.36
转向窗口	20	RAP-CT	125.83	83.73
持续机动窗口	2	CV-CT	41.19	24.24
持续机动窗口	2	RAP-CT	35.02	21.54
持续机动窗口	10	CV-CT	135.52	91.28
持续机动窗口	10	RAP-CT	117.09	81.43
持续机动窗口	20	CV-CT	94.32	94.65
持续机动窗口	20	RAP-CT	94.28	91.10

综合转向窗口和持续机动窗口结果可知,RAP-CT 的增益主要体现在对 CV-CT 误差累积的受约束补偿。对于一般转向样本,航速残差和航向变化率残差能够改善中心轨迹递推;对于持续机动样本,未来运动状态变化更复杂,单一历史窗口残差难以完全代表整个预测时域内的状态演化。因此,该补充实验进一步说明 RAP-CT 适用边界主要出现在持续强机动场景。

4 结 论

本文提出残差增强运动学轨迹预测方法 (RAP-CT),通过分析记录状态量与位置计算运动学参数的一致性,明确以位置计算运动学参数作为统一运动学参考,避免了直接采用记录状态量造成的递推基准偏差。实验表明,在 2、10 和 20min 预测时长下,终点误差相较 CV-CT 分别降低 44.6%、50.7%和 54.4%,优于传统机器学习模型与深度时序模型;消融实验验证了航速残差与航向变化率残差的互补作用,前者修正位移尺度,后者修正轨迹弯曲趋势。

与直接回归未来坐标的“黑箱”深度学习方法相比,RAP-CT 将数据驱动修正约束在航速和航向变化率等运动学变量上,通过显式运动学递推生成轨迹,既保留了物理一致性,又通过残差学习缓解了误差累积。同时,基于历史回测构建的经验误差范围,可为无人艇智能航行决策提供直观的误差尺度参考,弥补了现有研究对预测不确定性表达不足的缺陷。

未来研究可从以下方面进一步深化:一是引入在线学习机制,使残差模型随实时航行数据动态更新,以适应更复杂的机动场景;二是结合分位数回归或共形预测方法,将经验误差范围拓展为严格概率意义上的预测区间,提升预测结果的可靠性;三是将方法拓展至多艇协同场景,考虑船间交互影响,以支撑编队航行与避碰决策。

参考文献:

- [1] LIU Z, ZHANG Y, YU X, et al. Unmanned surface vehicles: An overview of developments and challenges[J]. Annual Reviews in Control, 2016, 41: 71-93. DOI: 10.1016/j.arcontrol.2016.04.018.
- [2] ZHANG X, WANG C, JIANG L, et al. Collision-avoidance navigation systems for maritime autonomous surface ships: A state of the art survey[J]. Ocean Engineering, 2021, 235: 109380. DOI: 10.1016/j.oceaneng.2021.109380.
- [3] ZHANG X C, FU X J, XIAO Z, et al. Vessel trajectory prediction in maritime transportation: Current approaches and beyond[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(11): 19980-19998. DOI: 10.1109/TITS.2022.3192574.
- [4] BAR-SHALOM Y, LI X R, KIRUBARAJAN T. Estimation with applications to tracking and navigation: theory algorithms and software[M]. New York: John Wiley & Sons, 2004. DOI: 10.1002/0471221279.

-
- [5] ZHAI G, MENG H D, WANG X Q, et al. A constant speed changing rate and constant turn rate model for maneuvering target tracking[J]. *Sensors*, 2014, 14(3): 5239-5253. DOI: 10.3390/s140305239.
- [6] ZHANG D Y, CHU X M, WU W X, et al. Model identification of ship turning maneuver and extreme short-term trajectory prediction under the influence of sea currents[J]. *Ocean Engineering*, 2023, 278: 114367. DOI: 10.1016/j.oceaneng.2023.114367.
- [7] LIN S Y, JIANG Y F, HONG F, et al. HDFormer: A transformer-based model for fishing vessel trajectory prediction via multi-source data fusion[J]. *Ocean Engineering*, 2025, 320: 120309. DOI: 10.1016/j.oceaneng.2025.120309.
- [8] JIANG J, ZUO Y, XIAO Y, et al. STMGF-Net: A spatiotemporal multi-graph fusion network for vessel trajectory forecasting in intelligent maritime navigation[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2024, 25(12): 21367-21379. DOI: 10.1109/TITS.2024.3363999.
- [9] GUO Z Y, QIANG H M, PENG X D, et al. Vessel trajectory prediction using vessel influence long short-term memory with uncertainty estimation[J]. *Journal of Marine Science and Engineering*, 2025, 13(2): 353. DOI: 10.3390/jmse13020353.
- [10] LANG X, WU D, MAO W G. Physics-informed machine learning models for ship speed prediction[J]. *Expert Systems with Applications*, 2024, 238: 121877. DOI: 10.1016/j.eswa.2023.121877.
- [11] ZHAO Y F, HU Z Q, DU W F, et al. Research on modeling method of autonomous underwater vehicle based on a physics-informed neural network[J]. *Journal of Marine Science and Engineering*, 2024, 12: 801. DOI: 10.3390/jmse12050801.
- [12] NIELSEN R E, PAPAGEORGIOU D, NALPANDIS L, et al. Machine learning enhancement of manoeuvring prediction for ship digital twin using full-scale recordings[J]. *Ocean Engineering*, 2022, 257: 111579. DOI: 10.1016/j.oceaneng.2022.111579.
- [13] KATH C, SCHILLING M, NAUMANN A, et al. Short-term inland vessel trajectory prediction with transformer-based models[C]//2022 IEEE International Conference on Data Mining Workshops (ICDMW). Piscataway: IEEE, 2022: 51-58. DOI: 10.1109/ICDMW58026.2022.00015.
- [14] 胡建涛, 李天姣, 康振, 等. 基于 GRU-MSAformer 模型的船舶轨迹预测[J]. *水下无人系统学报*, 2025, 33(2): 244-255. DOI: 10.3969/j.issn.1674-5558.2025.06.008.
- [15] 谷达京, 施哲源, 陈根良, 等. 基于神经网络的船体运动位姿预测方法[J]. *舰船科学技术*, 2022, 44(15): 55-59. DOI: 10.3404/j.issn.1672-7649.2022.15.011.
- [16] MALLESWAREN M, VAIDEHI V, IRWIN S, et al. IMM-UKF-TFS model-based approach for intelligent navigation[J]. *The Journal of Navigation*, 2013, 66(6): 859-877. DOI: 10.1017/S0373463313000360.
- [17] BODUNOV O, SCHMIDT F, MARTIN A, et al. Real-time destination and ETA prediction for maritime traffic[C]//DEBS '18: Proceedings of the 12th ACM International Conference on Distributed and Event-Based Systems. New York: ACM, 2018: 198-201. DOI: 10.1145/3210284.3220502.
- [18] YOU L, XIAO S, PENG Q, et al. ST-Seq2Seq: A spatio-temporal feature-optimized Seq2Seq model for short-term vessel trajectory prediction[J]. *IEEE Access*, 2020, 8: 218565-218574. DOI: 10.1109/ACCESS.2020.3041762.
- [19] 张保旭, 薛孝行. 考虑转向运动特征的船舶新航向距离计算模型[J]. *中国航海*, 2023(4): 15-19. DOI: 10.3969/j.issn.1000-4653.2023.04.003.